

## **Proyecto Integrador**

# **Mejora del Reconocimiento de Actividades Humanas mediante Fusión de Datos**

**Miguel A. Castillo**

**Asignatura: Reconocimiento de la Actividad Humana Basada en la Fusión de Datos con  
Python**

**Profesor: Antonio Armando Aguilera Güémez  
Universidad Autónoma de Yucatán  
Facultad de Matemáticas**

**3 de mayo de 2024**

# Mejora del Reconocimiento de Actividades Humanas mediante Fusión de Datos

Miguel A. Castillo

Facultad de Matemáticas

Universidad Autónoma de Yucatán, México

## **Resumen**

*El reconocimiento de la actividad humana (HAR, por sus siglas en inglés) es un campo de investigación vital en la intersección de la inteligencia artificial y la computación ubicua. En este estudio, se presenta un análisis exhaustivo y la construcción de un sistema para la mejora del Reconocimiento de la Actividad Humana Basado en la Fusión de Datos, implementado utilizando Python. El objetivo principal de este trabajo es mejorar la precisión y la robustez del reconocimiento de actividades humanas mediante la fusión de múltiples fuentes de datos. Para alcanzar este objetivo, se propone un enfoque que integra datos provenientes de múltiples sensores, incluyendo acelerómetros y giroscopios. Se evalúan tres métodos diferentes de fusión de datos para determinar el más efectivo en términos de precisión y eficiencia computacional. Los resultados obtenidos revelan que los tres métodos de fusión probados en el experimento lograron una precisión promedio superior al 95% en todas las métricas evaluadas, lo que demuestra la efectividad del enfoque propuesto. Las conclusiones derivadas de este estudio destacan la importancia de la fusión de datos en el reconocimiento de actividades humanas y proporcionan información valiosa para futuras investigaciones en este campo. Se discuten las implicaciones de los resultados obtenidos y se identifican posibles áreas para mejorar.*

**Palabras clave:** HAR, reconocimiento de la actividad humana, machine learning, métodos de fusión, clasificadores.

## 1. Introducción

El reconocimiento de la actividad humana (HAR) es una disciplina fundamental dentro del ámbito de la detección inteligente, que se centra en la extracción y análisis de características de actividad a partir de datos de series temporales generados por sensores. Este campo tiene aplicaciones diversas y cruciales en áreas como la atención médica inteligente, hogares inteligentes, sistemas de monitoreo, interacción humano-computadora y detección de caídas [1].

Actualmente, las técnicas de HAR se pueden clasificar ampliamente en tres categorías según la fuente de datos: reconocimiento de comportamiento humano basado en visión, reconocimiento de actividad humana a través de interacción ambiental y reconocimiento de actividad humana basado en sensores en el cuerpo humano [1]. Este último enfoque será el foco principal de este artículo.

El reconocimiento de la actividad humana (HAR) se sitúa en la intersección de la inteligencia artificial, donde su objetivo primordial radica en comprender y clasificar las actividades realizadas por los individuos mediante la interpretación de datos sensoriales. Para esta labor, los sistemas de aprendizaje máquina tienen la capacidad de prever el futuro en función de experiencias pasadas [2]. Para la tarea de clasificación basada en datos históricos (aprendizaje supervisado) [3], muchos optan por su modelo de clasificador preferido, como KNN, árboles de decisión, o bayes ingenuos. Sin embargo, para mejorar la robustez y el rendimiento de un sistema de aprendizaje máquina, se puede recurrir a una técnica llamada fusión de datos, que incorpora de manera integral los datos derivados de diferentes tecnologías para lograr resultados de clasificación y predicción más completos [4]. En este artículo, se emplearán métodos de conjuntos (ensembles), los cuales se centran en mejorar el rendimiento del sistema utilizando varios modelos para la clasificación en lugar de depender de uno solo para hacer predicciones [5]. El objetivo es obtener una predicción final que combine los resultados de distintas fuentes (modelos de clasificación base).

Este estudio abarca todos los conceptos y herramientas mencionados anteriormente con el fin de mejorar la precisión y la robustez del reconocimiento de actividades humanas mediante la fusión de múltiples fuentes de datos.

Este trabajo está organizado de la siguiente manera: en la sección 2 se describe la metodología utilizada. En la sección 3 se presentan los resultados obtenidos de cada estudio. En la sección 4 se analizan los resultados en el contexto de las preguntas de investigación. Por último, se presentan las conclusiones en la sección 5.

## 1. Método de investigación

Para llevar a cabo esta investigación, se utilizará un enfoque de estudio experimental en el contexto de la ingeniería de software, puesto que se utilizarán herramientas y técnicas necesarias para diseñar y llevar a cabo experimentos en un sistema [6] para el reconocimiento de la actividad humana. El proceso para realizar este estudio con un enfoque experimental se puede dividir en siete pasos [6]:

- Identificación del problema y objetivos de investigación: Se identifica claramente el problema que se desea abordar y los objetivos específicos que se desean lograr con el estudio experimental.
- Revisión de literatura: Se realiza una revisión exhaustiva de la literatura existente en el área relevante para comprender el estado actual del conocimiento, identificar brechas en la investigación y establecer una base teórica sólida para el estudio experimental.
- Formulación de hipótesis: Basándose en la revisión de literatura y en la comprensión del problema, se formulan hipótesis claras y específicas que puedan ser probadas mediante experimentación. Las hipótesis deben ser testables y estar relacionadas con los objetivos de investigación.
- Diseño experimental: Se diseña un experimento riguroso que permita probar las hipótesis de manera efectiva.
- Análisis de datos: Realiza un análisis estadístico apropiado de los datos recopilados para probar tus hipótesis y responder las preguntas de investigación.
- Interpretación de resultados: Se interpreta los resultados en términos de sus implicaciones para las hipótesis y objetivos de investigación. Se discute cualquier patrón o tendencia significativa que se haya observado y cómo estos resultados se relacionan con la literatura existente y la teoría subyacente.
- Conclusiones y recomendaciones: Se presentan las conclusiones basadas en los resultados del estudio y se ofrecen recomendaciones para futuras investigaciones o prácticas en el área. También se destacan las contribuciones y limitaciones del estudio y posibles áreas para futura exploración.

Como el objetivo principal del estudio es mejorar la precisión y la robustez del reconocimiento de actividades humanas mediante la fusión de múltiples fuentes de datos, se plantean las siguientes preguntas de investigación para lograr esta meta:

- PI.1 ¿Cuál es el impacto de la fusión de datos en la precisión y la robustez del sistema de reconocimiento de actividades humanas en comparación con enfoques convencionales que no utilizan fusión de datos?

- PI.2 ¿Cómo se comparan diferentes técnicas de fusión de datos en términos de su capacidad para mejorar el rendimiento del sistema de reconocimiento de actividades humanas?

## 2.1 Identificación y selección de fuentes

Para la investigación, se utilizará la base de datos Opportunity, la cual contiene actividades humanas registradas en un entorno rico en sensores: una habitación que simula un apartamento estudio con cocina, tumbona y acceso al aire libre, donde los sujetos realizan actividades matutinas diarias. Este incluye 72 sensores de 10 modalidades, integrados en el entorno, en objetos y en el cuerpo [7]. Los datos fueron capturados a 30 hz (30 ejemplos por segundo). Los datos están compuestos por las grabaciones de 4 sujetos que incluyen solo sensores colocados en el cuerpo; para cada sujeto se proporcionó 5 grabaciones no segmentadas. Las etiquetas están disponibles para cuatro de las sesiones, mientras que las dos últimas sesiones se utilizó por parte de los organizadores para evaluar. Además, el sujeto 4 se utiliza para evaluar la robustez al ruido. Por esta razón, se agregó ruido rotacional a los datos de este sujeto [7]. La siguiente tabla proporciona las sesiones las cuales cuentan con etiquetado (labels).

	S1	S2	S3	S4
Drill	●	●	●	●
ADL 1	●	●	●	●
ADL 2	●	●	●	●
ADL 3	●	●	●	●
ADL 4	●			
ADL 5	●			

Las sesiones incluyen 72 sensores de 10 modalidades, integrados en el entorno, en objetos y en el cuerpo. Los sujetos llevaban una chaqueta de movimiento hecha a medida compuesta por 5 unidades de medición inercial XSense conectadas en red a través de RS485. Además, se utilizaron 12 sensores de aceleración Bluetooth en las extremidades y sensores inerciales comerciales InertiaCube3 ubicados en cada pie. El total de sensores utilizados en la base de datos son:

- Sensores llevados en el cuerpo: 7 unidades de medición inercial, 12 sensores de aceleración 3D, 4 informaciones de localización 3D.
- Sensores de objetos: 12 objetos con aceleración 3D y velocidad de giro 2D.
- Sensores ambientales: 13 interruptores y 8 sensores de aceleración 3D.

### 3. Resultados

#### 3.1 Identificación del problema y objetivos de investigación

El conjunto de datos OPPORTUNITY Dataset for Human Activity Recognition proporciona una valiosa fuente de información para abordar el problema de reconocimiento de actividades humanas en entornos del mundo real. El objetivo principal de esta investigación es evaluar el rendimiento y la eficacia de diferentes técnicas de fusión de datos para el reconocimiento de actividades humanas utilizando el conjunto de datos OPPORTUNITY. Se busca mejorar la comprensión y el desarrollo de sistemas de reconocimiento de actividad efectivos y confiables que puedan aplicarse en una variedad de contextos prácticos.

#### 3.2 Revisión de literatura

Como se mencionó anteriormente, para abordar esta problemática se utilizarán sistemas de aprendizaje máquina en conjunto, esto con el fin de crear un modelo más robusto y con mejor rendimiento [5]. Sin embargo, antes de diseñar estos sistemas robustos, es importante considerar una variedad de temas relacionados que puedan influir en los resultados del experimento. Que van desde el análisis de datos hasta el preprocesamiento de estos para su implementación en los modelos. Diferentes autores comparten los siguientes puntos como importantes al momento de construir cualquier sistema de aprendizaje máquina:

- Observar los datos: Un punto primordial en la construcción de cualquier sistema de aprendizaje máquina es conocer los datos con los que vamos a trabajar, esto con la intención de saber si estos datos son útiles para conocer nuestro objetivo [3]. En el contexto de esta investigación se utilizarán herramientas en el lenguaje de programación Python para visualizar nuestra base de datos, esto con la intención de entenderlos y comprender cómo se relacionan con nuestro objetivo.
- Manejo de datos ausentes: Una fase crucial en el procesamiento de nuestros datos es abordar la presencia de valores nulos, ya que la falta de coherencia y continuidad en los datos puede afectar considerablemente los cálculos subsiguientes [3]. Para abordar estos datos faltantes, se puede optar por la estrategia de imputación hacia adelante. Al utilizar la observación previa como sustituto, el "forward fill" contribuye a mantener la continuidad en los datos, permitiendo un análisis o modelado ininterrumpido [8].
- Escalamiento de datos: Una práctica común en los datos es la reescalación, esto debido a que la gran mayoría de los algoritmos de aprendizaje máquina son sensibles al escalado de los datos [3].

- Fuga de datos: Situación en la que información indebida o inapropiada del conjunto de datos de entrenamiento "se filtra" o se incorpora accidentalmente al modelo durante el proceso de entrenamiento. [5]. Este problema se soluciona al preprocesar los datos de entrenamiento y de prueba por separado.
- Sobreajuste: Ocurre cuando se ajusta un modelo demasiado de cerca a las particularidades del conjunto de entrenamiento y se obtiene un modelo que funciona bien en el conjunto de entrenamiento pero no puede generalizar a nuevos datos.
- Desbalance de clases: Es un problema en las tareas de clasificación donde hay una diferencia sustancial en el número de muestras en cada clase de datos de entrenamiento [5]. Existen varios enfoques para manejar esta situación, que van desde modificar las instancias reduciendo la cantidad de ejemplos de la clase mayoritaria o duplicar instancias de la clase minoritaria, utilizar métricas específicas para evaluar un modelo que lidie con este imbalance, o directamente indicarle al modelo que usemos que tome en cuenta este desbalance de clases.

En el contexto del reconocimiento de la actividad humana, es importante considerar lo siguiente:

- Actividades simples humanas: Las actividades humanas simples consideran la postura y el movimiento del cuerpo para definir diversas actividades. Estas incluyen actividades como correr, caminar, trotar, etc [9]. En el contexto de esta investigación se ha optado por enfocarse exclusivamente en el reconocimiento de actividades humanas simples, esta elección tiene como objetivo estudiar de manera más manejable y comprensible el reconocimiento de la actividad humana.

### **3.3 Formulación de hipótesis**

Basándose en todas las consideraciones teóricas y prácticas para la creación de un sistema basado en la fusión de datos, se plantea la hipótesis de que el modelo entrenado será capaz de reconocer con precisión y eficacia las actividades simples humanas en la base de datos OPPORTUNITY. Se espera que el modelo, después de ser sometido a un proceso de entrenamiento que incluye la observación y comprensión de los datos, así como técnicas de preprocesamiento pueda generalizar adecuadamente a nuevas instancias.

### **3.4 Diseño experimental**

Para comenzar, se procede cargando la base de datos, donde cada sujeto se encapsula en su propio conjunto de datos para un análisis integral. Es importante señalar que, según la documentación de la base de datos, solo las primeras 4 sesiones están etiquetadas. Por lo tanto, para los propósitos de esta

investigación, que implican aprendizaje supervisado, se utilizarán exclusivamente estas sesiones para el entrenamiento y la evaluación del modelo.

Al analizar los datos, se observa una diversidad de rangos numéricos en los que se distribuyen las diferentes características, lo que sugiere la necesidad de escalar nuestros datos. También se identifica la presencia de una gran cantidad de sensores, principalmente acelerómetros, giroscopios y magnetómetros, la mayoría de los cuales son de tres ejes. Además, se detecta una cantidad significativa de datos faltantes en la base de datos. Por último, se examinan diversas visualizaciones que describen el comportamiento de los datos, revelando un sesgo considerable en varias características. Es importante destacar que se observa una correlación entre diferentes características, lo que indica la presencia de patrones en el comportamiento de los datos.

Posteriormente, se procede a la partición de los datos en las actividades simples humanas. En el contexto de la base de datos utilizada, nos centraremos exclusivamente en la etiqueta "Locomotion", que incluye actividades como estar parado, caminar, sentarse y acostarse. Estas actividades simples pueden identificarse únicamente con sensores en el cuerpo [10].

Para el procesamiento de los datos, se aplican técnicas de extracción de características, que buscan obtener características significativas de nuestros datos en ventanas de tiempo de 3 segundos. Esto se realiza con el objetivo de reducir el número de ejemplos a una cantidad más manejable, mientras se conserva información importante de los datos [11]. Específicamente, se utilizan doce estadísticos que describen el comportamiento de cada sensor (media, desviación estándar y máximo de cada eje, media de la magnitud de los tres ejes, desviación estándar de la magnitud y área bajo la curva de la magnitud) considerando que cada sensor consta de tres ejes.

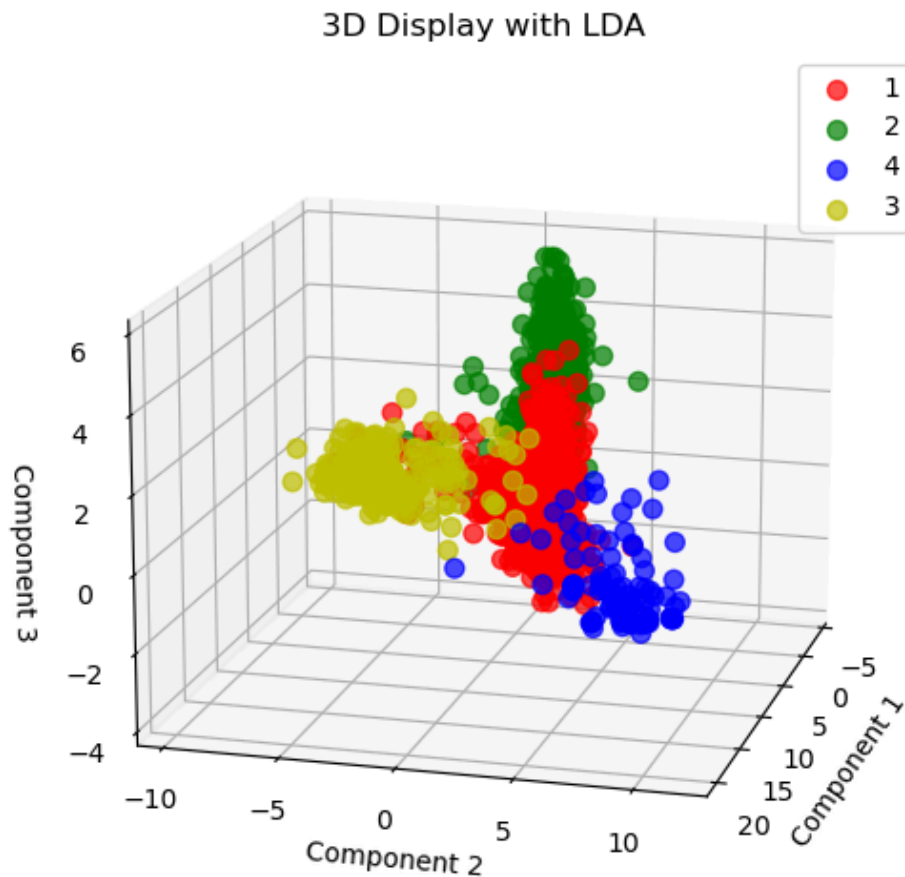
Una vez extraídas estas características, se realiza una selección de las más significativas para reducir la dimensionalidad del conjunto de datos. Esta selección se basa en un puntaje que indica cuán bien están relacionadas las características con la variable objetivo. Se utiliza el análisis de varianza (ANOVA) para calcular este puntaje en relación con la variable objetivo en un problema de clasificación [12].

Antes de continuar, se aplica el escalado de los datos para estandarizarlos y garantizar que todas las características tengan un impacto equitativo en el modelo.

Luego, se realiza una reducción adicional de características utilizando la técnica de Análisis Discriminante Lineal (LDA), que es una técnica de reducción de dimensionalidad supervisada. El objetivo de esta técnica es aumentar la distancia entre las medias de las clases y reducir la variabilidad dentro de cada clase [12].

Una vez obtenidos estos componentes principales, se visualizan las diferentes agrupaciones de las clases en un espacio tridimensional para comprender cómo se distribuyen los datos y detectar posibles desbalances en las clases.





Al detectar un desbalance en las clases, se decide abordar este problema mediante métodos a nivel de modelo que consideren la existencia de desbalance de clases.

Con una representación significativa de los datos originales en un formato más simple para nuestro modelo de aprendizaje automático basado en la fusión de datos, se procede a evaluar el rendimiento de tres clasificadores diferentes: Regresión Logística, Random Forest y Perceptrón. Para evaluar el rendimiento de los clasificadores, se utiliza una estrategia de validación cruzada, dividiendo repetidamente los datos y entrenando múltiples modelos [3]. El número de iteraciones que se van a realizar las pruebas son el total de combinaciones que se pueden hacer con los sujetos datos.

$$Total\ iteraciones = 4C3 = \left(\frac{4!}{(4-3)! 3!}\right) = \frac{4 \times 3 \times 2 \times 1}{(1)(3 \times 2 \times 1)} = \frac{24}{6} = 4$$

Finalmente, se entrenan y prueban tres métodos de fusión de datos distintos: Agregación con Random Forest, Votación con Regresión Logística, Random Forest y Bayes Ingenuo, y AdaBoost. La

evaluación de estos métodos se realiza utilizando la misma estrategia de validación cruzada y las mismas métricas utilizadas para los clasificadores individuales

### 3.5 Análisis de datos

Se llevaron a cabo dos evaluaciones de validación cruzada para dos modelos de aprendizaje supervisado diferentes: uno que emplea técnicas de fusión de datos y otro que no. Los resultados obtenidos en las métricas evaluadas se presentan a continuación:

#### Modelo sin implementación de fusión de datos

Como se mencionó anteriormente, los clasificadores utilizados fueron Regresión Logística, Random Forest y Perceptrón.

##### Combinación 1:

	Accuracy	Precision	Recall	F1-score
0	0.949153	0.955246	0.949153	0.950168
1	0.952542	0.954471	0.952542	0.952850
2	0.948305	0.950527	0.948305	0.948877

##### Combinación 2:

	Accuracy	Precision	Recall	F1-score
3	0.939752	0.946238	0.939752	0.940696
4	0.950932	0.952577	0.950932	0.951258
5	0.935404	0.943304	0.935404	0.936468

##### Combinación 3:

	Accuracy	Precision	Recall	F1-score
6	0.965149	0.965573	0.965149	0.965238
7	0.960882	0.961372	0.960882	0.960887
8	0.930299	0.935726	0.930299	0.930262

##### Combinación 4:

	Accuracy	Precision	Recall	F1-score
9	0.943042	0.943719	0.943042	0.943174
10	0.931392	0.932000	0.931392	0.931224
11	0.926214	0.930202	0.926214	0.926587

Media de los resultados obtenidos:

Accuracy	0.943207
Precision	0.946466
Recall	0.943207
F1-score	0.943601

**Modelo con implementación de fusión de datos**

Como se mencionó anteriormente, los métodos de fusión de datos utilizados fueron Agregación con Random Forest, Votación con Regresión Logística, Random Forest y Bayes Ingenuo, y AdaBoost.

**Combinación 1:**

	Accuracy	Precision	Recall	F1-score
0	0.961864	0.963419	0.961864	0.962205
1	0.958475	0.962503	0.958475	0.959165
2	0.961864	0.963156	0.961864	0.962142

**Combinación 2:**

	Accuracy	Precision	Recall	F1-score
3	0.950932	0.952801	0.950932	0.951286
4	0.945963	0.950292	0.945963	0.946637
5	0.954037	0.955005	0.954037	0.954235

**Combinación 3:**

	Accuracy	Precision	Recall	F1-score
6	0.959459	0.960053	0.959459	0.959468
7	0.963727	0.963815	0.963727	0.963762
8	0.960171	0.960480	0.960171	0.960092

**Combinación 4:**

	Accuracy	Precision	Recall	F1-score
9	0.935275	0.936276	0.935275	0.935026
10	0.944337	0.944533	0.944337	0.944375
11	0.930744	0.932823	0.930744	0.930592

**Media de los resultados obtenidos**

Accuracy	0.950901
Precision	0.952477
Recall	0.950901
F1-score	0.951045

### 3.6 Interpretación de resultados

Después de llevar a cabo el diseño experimental siguiendo las recomendaciones teóricas y prácticas mencionadas en la revisión de la literatura, se evaluaron los modelos basados en la fusión de datos. Los resultados obtenidos muestran que en todas las métricas evaluadas, los modelos no bajan del 93% de precisión. Estos resultados se obtuvieron mediante la validación cruzada, lo que indica que nuestros modelos cumplen con la hipótesis planteada inicialmente. Además, se realizaron pruebas en modelos que no implementan la fusión de datos, y aunque obtuvieron resultados similares, en los métodos de fusión de datos se obtuvo un mejor rendimiento en todas las métricas. Este hallazgo respalda la eficacia del enfoque de fusión de datos y sugiere que la observación, comprensión y preprocesamiento de los datos contribuyeron significativamente a la capacidad de generalización de los modelos a nuevas instancias.

### 4. Discusiones

En un estudio similar, que emplea una red neuronal recurrente (específicamente LSTM) para clasificar actividades humanas simples en la base de datos Opportunity, se alcanzaron resultados comparables. Al igual que en nuestro trabajo, se realizaron validaciones cruzadas y pruebas de múltiples modelos. Se calcularon diversos parámetros de evaluación que arrojaron una precisión en el rango del 80% al 95%, con un rendimiento destacado del 94.8% en el modelo más óptimo [13]. Este logro resalta el potencial inherente de las redes neuronales en tareas de clasificación, aunque cabe destacar que los resultados obtenidos a través de un modelo basado en la fusión de datos aún superan ligeramente estos estándares.

### 5. Conclusiones y recomendaciones

Para abarcar las conclusiones de la investigación, se plantearon dos preguntas de investigación las cuales serán respondidas en base a los resultados obtenidos.

- PI.1 ¿Cuál es el impacto de la fusión de datos en la precisión y la robustez del sistema de reconocimiento de actividades humanas en comparación con enfoques convencionales que no utilizan fusión de datos?

El impacto de la fusión de datos en la precisión y la robustez del sistema de reconocimiento de actividades humanas es significativo. Los resultados obtenidos mostraron que los modelos basados en la fusión de datos lograron una precisión promedio por encima del 95%, mientras que los modelos que no implementaron fusión de datos también obtuvieron resultados comparables pero ligeramente inferiores. Esto sugiere que la fusión de datos mejora la

precisión y la capacidad de generalización del sistema para el reconocimiento de las actividades humanas.

- PI.2 ¿Cómo se comparan diferentes técnicas de fusión de datos en términos de su capacidad para mejorar el rendimiento del sistema de reconocimiento de actividades humanas?

Las diferentes técnicas de fusión de datos se compararon en términos de su capacidad para mejorar el rendimiento del sistema de reconocimiento de actividades humanas. Los resultados mostraron que todas las técnicas de fusión de datos evaluadas lograron una precisión por encima del 93%, lo que indica que todas son efectivas para mejorar el rendimiento del sistema. Sin embargo, se observó que algunos métodos de fusión de datos proporcionaron un rendimiento ligeramente mejor en términos de métricas de evaluación, como el accuracy, precisión, el recall y el F1-score, en comparación con otros métodos. Esto sugiere que la selección de la técnica de fusión de datos adecuada puede tener un impacto significativo en el rendimiento del sistema de reconocimiento de actividades humanas.

Es esencial señalar que, si bien la técnica de fusión de datos puede ofrecer mejoras en la precisión, implica un proceso más complejo y un consumo computacional más elevado en comparación con un enfoque de clasificador único [5]. En el contexto de nuestra problemática, aunque los resultados alcanzados son apenas superiores, es importante considerar un balance entre rendimiento y eficiencia computacional.

## 6. Referencias

- [1] Wei, X., Wang, Z. TCN-attention-HAR: human activity recognition based on attention mechanism time convolutional network. Sci Rep 14, 7414 (2024). <https://doi.org/10.1038/s41598-024-57912-3>
- [2] Reyes, J. (2015). Smartphone-Based Human Activity Recognition
- [3] Müller, A. C., and Guido, S., Introduction to machine learning with Python: a guide for data scientists, O'Reilly Media, Inc. (2016), ISBN-13: 978-1-449-36941-5.
- [4] Qianqian Li, Chaoyang Zhang, Huawei Wang, Shengfan Chen, Wei Liu, Yi Li, Jianxun Li, Machine learning technique combined with data fusion strategies: A tea grade discrimination platform, Industrial Crops and Products, Volume 203, 2023, 117127, ISSN 0926-6690, <https://doi.org/10.1016/j.indcrop.2023.117127>.
- [5] Huyen, C. (2022). Designing Machine Learning Systems An Iterative for Production-Ready Applications.
- [6] Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., & Wesslén, A. (2000). Experimentation in Software Engineering. Springer Science & Business Media.

- [7] Roggen,Daniel, Calatroni,Alberto, Nguyen-Dinh,Long-Van, Chavarriaga,Ricardo, and Saghah,Hesam. (2012). OPPORTUNITY Activity Recognition. UCI Machine Learning Repository. <https://doi.org/10.24432/C5M027>
- [8] TradingStrategy.ai documentation, TradingStrategy.ai (2024).
- [9] Gupta, S. (2021). Deep learning based human activity recognition (HAR) using wearable sensor data.
- [10] Akter, M.; Ansary, S.; Khan, M.A.-M.; Kim, D. Human Activity Recognition Using Attention-Mechanism-Based Deep Learning Feature Combination. Sensors 2023, 23, 5715. <https://doi.org/10.3390/s23125715>
- [11] Enrique Garcia-Ceja, Carlos E. Galván-Tejada, Ramon Brena. (2017). Multi-view stacking for activity recognition with sound and accelerometer data
- [12] Raschka, S., and Vahid M., Python Machine Learning: Machine Learning and Deep Learning with Python, Scikit-Learn, and TensorFlow. Second edition ed, Packt Publishing (2017), ISBN 978-1-78712-593-3.
- [13] <https://github.com/yashbhagat3/Human-Activity-Recognition-using-LSTMs-Opportunity-UCI-Datase>
- t-